
統計概念整理

1. ETL Pipelines

- ETL stands for **Extract, Transform, Load**. It's a process used to move data from source systems into a data warehouse.

2. Avro

- 二進位格式可同時儲存資料及其綱要，使其能在未具備原始系統背景的情況下，透過不同系統進行後續處理。

3. Parquet

- **Columnar** storage format optimized for analytics. Allows for efficient compression and encoding schemes.
- 為分析優化的欄式儲存格式。可實現高效的壓縮與編碼方案。

4. Data Processing

■ Imputing Missing Data

- ◆ 概念：用觀測資訊填補缺失值，使資料可用且盡量減少偏差。先判斷缺失機制：MCAR（完全隨機）、MAR（依其他變數）、MNAR（依自身值）。插補器只在訓練集擬合，Pipeline 化避免洩漏。

◆ Mean Replacement（平均值插補）

- 做法：用訓練集的平均數替數值缺失（類別用眾數，偏態建議用中位數）。
- 優缺：快、穩定；但壓縮變異、扭曲分布、削弱相關、低估不確定性。
- 適用：缺失比例低、近似常態/對稱分布、作為基準線。

◆ Dropping（刪除）

- 做法：刪含缺失的列，或刪缺失比例過高的欄。
- 優缺：簡單、無額外假設；但減少樣本、若非 MCAR 易產生偏差。
- 適用：MCAR 且比例很小（ $\sim < 5\%$ ）；或欄位缺失極高且非關鍵。

◆ Machine Learning（模型式處理）

- 做法：**KNN/回歸/隨機森林插補、多重插補(MICE)**；或選用能原生處理缺失的樹模型（XGBoost/LightGBM/CatBoost）。
- 優缺：較能保留結構與不確定性（多重插補）；成本較高，易過擬合/資料洩漏。
- 實務要點：保留「缺失指示變數」；對 MNAR 需業務特徵或建模缺失機制；交叉驗證比較策略效果。

■ Handling Unbalanced Data

- ◆ 概念：**類別分佈嚴重不均**（少數類很稀有），模型傾向預測多數類；「準確率」容易誤導。

- ◆ 影響：偏差評估、決策閾值不當、召回率低；需用對的指標與取樣策略。

◆ Oversampling（少數類上採樣）

- 定義：**以複製或合成方式增加少數類樣本**（最簡單為隨機重複）。
- 優點：保留全部資料訊息；在極度不平衡時能提升召回。
- 風險：過擬合（重複樣本）、訓練時間變長；須僅在訓練折內執行避免洩漏。

◆ Undersampling（多數類下採樣）

- 定義：隨機或基於規則移除部分多數類樣本。
- 優點：快、簡單、訓練加速。
- 風險：丟失有用訊號；資料量本就不大時不宜。可用 Tomek links、ENN 改善邊界品質。

◆ SMOTE(Synthetic Minority Over-sampling TEchnique)

- 定義：在少數類樣本及其近鄰之間線性插值，合成新少數類樣本。
- 優點：比單純複製更能擴充決策邊界，常提升召回/F1。
- 風險與變體：易在類別重疊處引入噪音；類別偏斜/邊界問題可用 Borderline-SMOTE、SMOTE+ENN、SMOTETomek；類別型特徵用 SMOTENC。只在訓練折內做。

■ Handling Outliers

- ◆ 概念/影響：顯著偏離大多數樣本的值；可能是噪音或真實稀有事件。會拉動均值/方差、放大 MSE、擾亂距離度量與係數估計。先判斷是否保留（若代表高風險/高價值事件）。
 - ◆ Binning
 - 將連續值切箱（等頻/分位數），極端值落在端箱；或 Winsorization（封頂/封底到分位數）。優點：降敏感度；缺點：損失細節。
 - ◆ Transforming
 - $\log/\sqrt{\cdot}$ 、Box-Cox/Yeo-Johnson 降偏態並縮小極端影響；常搭配 clipping。回歸可對 y 轉換並在推論反轉。
 - ◆ Encoding
 - 加入 outlier 指示變數；類別特徵的稀有值合併為 “Other” 或用頻率/目標編碼（需平滑）以穩定估計。
 - ◆ Scaling / Normalization
 - RobustScaler（中位數/IQR）優先；StandardScaler 前先 clip；Min-Max 對離群敏感；深度學習可加值/梯度裁切。
 - ◆ Shuffling
 - 訓練時隨機打散樣本，讓離群樣本均勻分佈至批次，穩定 SGD/BatchNorm；可配小學習率與 early stopping。
-

5. Partial Dependence Plots (PDPs)

- 定義：一種可視化工具，用於分析機器學習模型的預測與特定特徵之間的關係。它通過固定一個或幾個特徵的值，觀察其他特徵變化時模型預測的變化，以幫助理解模型對這些特徵的依賴程度。

6. Shapley Values

- 定義：一種來自合作博弈理論的數學概念，主要用於評估個體在合作中的貢獻程度。在機器學習中，Shapley 值用於解釋模型預測，能夠確定特定特徵對模型輸出的貢獻。
-

7. Natural Language Processing(NLP)

- 定義：以統計與深度學習讓機器理解/生成自然語言（分詞、嵌入、Transformer）。
- 分詞 (Tokenization/Word Segmentation)
 - 定義：把原始文字切成「可處理的單位」tokens。中文常指「斷詞」；現代模型多用子詞法（如 BPE、WordPiece）以降低未登錄詞問題。

■ 嵌入 (Embedding)

- 定義：把每個 token/句子映射到稠密向量空間，使語意相近者距離更近；可為靜態 (Word2Vec/GloVe) 或情境化 (BERT 類)。

■ Transformer

- 定義：以自注意力 (Self-Attention) 為核心的深度學習架構，並行計算、擅長捕捉長距依賴；含 Encoder/Decoder 變體 (BERT、GPT、T5)。
-

8. Named Entity Recognition (NER)

- 定義：是自然語言處理 (NLP) 中的一項技術，旨在識別和分類文本中的專有名詞，例如人名、地名、組織名和其他具體實體。它的主要目的是將文本中有意義的信息提取出來，便於後續的分析和處理。
-

9. Automatic Speech Recognition (ASR)

- 定義：將人類語音轉換為可讀的文本。ASR 系統通過分析語音音頻，識別語音中的詞彙和句子結構，並將其轉換成書面文字。
-

10. Personally Identifiable Information (PII)

11. SageMaker's Built-In Algorithms

■ Linear Learner

■ XGBoost(eXtreme Gradient Boosting)

- 定義：XGBoost 是一種強大的增強學習算法，主要用於監督式學習任務，特別是在回歸和分類問題中的性能優越。它基於梯度提升框架，通過結合多個弱預測模型（通常是決策樹），形成一個強大的預測模型。XGBoost 提供了並行處理、正則化和自動處理缺失值等功能，從而提升了訓練速度和模型表現。
- 白話：想像你在組建一個團隊，每個成員都有不同的技能，透過合作來打敗競爭對手。XGBoost 就像是這個團隊，它將許多簡單的決策樹（成員）結合起來，形成一個強大的模型，幫助你更準確地預測結果。
- 正則化：可以防止過擬合，使模型更具泛化性。
- max_depth (XGBoost) :
 - 定義：限制每棵樹的最大深度（層數）。控制模型可擬合的互動階數與複雜度。
 - 影響：
 - ◆ 值大 → 更複雜、可擬合高階特徵交互，但易過擬合、訓練/記憶體/延遲上升。
 - ◆ 值小 → 模型更平滑、泛化較好，但可能欠擬合。
 - 偏差 - 變異 (Bias - Variance) :
 - ◆ max_depth ↑ → 偏差 ↓、變異 ↑
 - ◆ max_depth ↓ → 偏差 ↑、變異 ↓

■ stochastic gradient descent (SGD)

- 定義：隨機梯度下降是一種優化算法，用於訓練機器學習模型，特別是神經網絡。它通過逐一處理訓練數據中的每一個樣本，來更新模型參數，以減少成本函數。與傳統的批量梯度下降相比，SGD 每次更新只使用單一樣本（或少量樣本），這使得其計算較為快速和靈活。

- 白話：想像你在找一個山谷的最低點，但每次只走一步（樣本），然後根據你當前的位置調整前進的方向。這樣做能讓你更快找到最低點，雖然可能不會總是選擇最佳的方向，但總體上能穩步接近目標。
- 學習率（Learning Rate, LR）的角色：
 - ◆ LR 太大：loss 爆炸、震盪不收斂、出現訓練/驗證指標忽上忽下。
 - ◆ LR 太小：收斂很慢，容易卡在次優點；訓練/驗證同步緩慢上升。
 - ◆ 合適 LR：初期下降快速，中後期平穩收斂，驗證指標持續改善。

■ Seq2Seq

- 是編碼器-解碼器的深度學習架構，將輸入序列映射為輸出序列，常搭配注意力機制與 beam search 解碼。常見於機器翻譯、摘要產生、對話回覆、語法更正等任務。

■ DeepAR

- DeepAR 是 SageMaker 的機率式時間序列預測法，採自迴歸 RNN，可跨多序列學習；輸出分位數/機率區間，常用於需求、流量與能源負載預測。

■ BlazingText

- BlazingText 是 SageMaker 內建高效文字演算法，實作 Word2Vec 與 fastText 式監督分類，支援分散/多 GPU 與 Pipe 模式；適用於詞向量訓練、語意檢索、主題/意圖分類等。

■ Object Detection

- 物件偵測是電腦視覺任務，同時定位與分類影像中的多個目標，輸出每個物件的邊框與類別機率。常見方法含二階段（Faster R-CNN）與單階段（YOLO/SSD），應用於自駕、監控、零售盤點與製造瑕疵檢測。
- 在圖中同時「定位+分類」多個物件

■ Image Classification

- 影像分類是電腦視覺任務，將整張影像判為一或多個類別（單/多標籤），多用 CNN 或 Vision Transformer，輸出類別與機率。應用：瑕疵檢測、醫療影像、內容審核、圖像檢索。
- 判斷整張圖屬於哪些類別（單/多標籤）

■ LightGBM

- LightGBM 是一個以梯度提升樹（GBDT）為核心的開源機器學習框架，用決策樹疊代提升來解決分類與迴歸問題，特別擅長表格型資料。
- 使用場景：表格分類/迴歸、排序(CTR/搜尋)、風控、推薦、特徵重要度。
- 定義：GBDT (Gradient Boosting Decision Trees)
 - ◆ 以負梯度作為擬合目標，逐步疊加 CART 弱學習器以最小化損失；關鍵超參：學習率、樹深、樹數、子採樣、正則。
 - ◆ 白話：一棵棵小樹輪流修正前一輪的錯，愈補愈準（序列式 boosting）。
 - ◆ 使用場景：表格分類/迴歸、排序(CTR/搜尋)、風控/反詐；
 - ◆ 常見實作：XGBoost、LightGBM、CatBoost。

■ Semantic Segmentation(語義分割)

- 定義：逐像素分類，為每個像素賦予語義類別，輸出全圖遮罩；不分個體（不同實例同類合併）。
- 使用場景：自駕道路理解、醫學影像器官/腫瘤、遙測地物、工業瑕疵檢測。

■ Random Cut Forest(RCF)

- 定義：以隨機超平面反覆切割建多棵樹，依點的「孤立度」給異常分數的無監督法，支援流式/增量。

- 使用場景：時序突變、詐欺偵測、感測器故障、KPI 異常；可用 SageMaker 訓練。

■ Neural Topic Model(NTM)

- 定義：以 VAE 學習文件→主題與詞機率分佈的無監督模型；常用 BoW，SageMaker 提供內建 NTM。

- 白話：自動把大量文章分成幾個主題。

- 使用場景：文件探索、索引/搜尋、推薦特徵、客服工單分群。

■ Latent Dirichlet Allocation(LDA)

- 定義：生成式主題模型；文件↔主題、主題↔詞皆設 Dirichlet 先驗，吉布斯/變分推斷估參。

- 白話：把文章拆成多個主題，每主題是一袋代表詞。

■ K-Nearest-Neighbors(KNN)

- 定義：基於距離的惰性學習；以 K 個最近鄰投票/平均進行分類/回歸，受距離度量、K 值、特徵縮放影響。

- 白話：找你最像的幾個鄰居，看多數怎麼標就跟著判。

■ K-Means

- 定義：迭代尋找 k 個質心，最小化簇內平方誤差；對 k、初始化與尺度敏感（k-means++/mini-batch；SageMaker 內建）。

- 白話：把資料分成 k 群，讓每群離中心都更近。

■ Principal Component Analysis(PCA)

- 定義：以協方差矩陣特徵分解或 SVD 找方差最大且正交的主成分，用於降維與去噪。

- 白話：把多變量旋轉到新座標，抓出最有資訊的方向。

■ Anomaly detection

- 異常偵測：用於少樣本或未知標籤的離群點。

■ Linear regression

- 線性迴歸：連續目標。

■ Logistic regression

- 邏輯迴歸：處理二分類，輸出機率，易於解讀與設定決策閾值。

■ Factorization Machines

■ IP Insights

12. Training loss 與 Validation loss

■ Training loss

- 模型在訓練資料上的平均損失。反映是否學到資料內部模式與是否收斂。

■ Validation loss

- 模型在驗證資料上的平均損失，反映泛化能力，用於模型選擇、早停、超參數調整。

■ 常見走勢判讀：

Training loss	Validation loss	可能情形	解決方法
高且緩慢下降	高且緩慢下降	欠擬合/高 Bias	增模型容量、特徵、訓練更久、調高學習率。
下降	先降後升	過擬合/高 Variance	正則化、資料增強、早停、Dropout

同步震盪	同步震盪	學習率過大	降低學習率、加梯度裁剪、增大 batch
兩者差距很大且持續	兩者差距很大且持續	資料洩漏或分佈差異	檢查切分、特徵洩漏、分層抽樣
---	一直高但指標 (如 F1) 好	訓練目標與評估指標不一致	調整損失或決策閾值

■ Dropout

- 一種正則化。訓練時以機率 p 隨機把部分神經元輸出設為 0，迫使網路不依賴特定路徑，降低過擬合。推論時不丟棄。

13. 卷積神經網路 (CNN)

- 定義：CNN 是用於視覺資料的深度學習模型，含「卷積層」做特徵提取、「池化層」降維抗噪、「全連接層」完成分類/回歸；具參數共享與局部連接，保留空間結構。
- 白話：像一組越來越挑剔的「智慧濾鏡」，先抓邊緣，再抓紋理/形狀，最後認出物體。
- 使用場景：影像分類、物件偵測、語義分割、人臉辨識、醫學影像、遙測、自動駕駛視覺。

14. 循環神經網路 (RNN)

- 定義：RNN 處理序列資料，透過隱藏狀態在時間步傳遞歷史訊息，能應對可變長序列。
- 白話：像「有記憶力的網路」，每步都參考前面結果，適合前後有關聯的資料。
- 使用場景：語音辨識、時間序列預測、語言模型與序列標註；注意梯度消失/爆炸，常用 LSTM/GRU 改良穩定訓練。

15. Recall (召回率) (分母為真正為 positives)

$$\frac{TRUE POSITIVES}{TRUE POSITIVES + FALSE NEGATIVES}$$

- $TRUE POSITIVES + FALSE NEGATIVES$
- 所有真正的正類中，抓到多少。
- 當漏判一個正例的代價很高時（也就是 FN 代價高），就要提高 Recall。
 - i.e., fraud detection

16. Precision (精確率) (分母為模型判斷為 positives)

$$\frac{TRUE POSITIVES}{TRUE POSITIVES + FALSE POSITIVES}$$

- $TRUE POSITIVES + FALSE POSITIVES$
- 被判為正類者中，有多少是真的。
- 當把負例誤判為正的代價很高（FP 成本高）時，應優先追求高 Precision。

17. Specificity (特异性，真陰性率)

$$Specificity = \frac{TN}{TN + FP}$$

- $TN + FP$
- 所有真正的負類中，判對多少。
- 當「誤報」成本很高時（即 FP 代價大），需提高 Specificity。
 - 例：無害郵件被標成垃圾信、健康人被判定為陽性會造成不必要的恐慌與後續成本。

18. Accuracy

- $Accuracy = (TP + TN) / (TP + FP + FN + TN)$ 。
- 定義：整體判對比例，

- 使用場景：多類且類別平衡的基準；影像/文件分類；不適於嚴重類別不平衡或錯誤代價不對稱情境。

19. F1 Score

$$\frac{2TP}{2TP+FP+FN}$$

- $2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$
- Precision 與 Recall 的調和平均。衡量「預測純度」與「覆蓋率」的折衷。取值 0-1，越高越好。
- 為何用調和平均：對任一項很低時懲罰更重；避免算術平均掩蓋極端值。

20. Perplexity

- 定義：困惑度= $\exp(\text{交叉熵})$ ，衡量語言模型對測試序列的不確定性；越低越好。
- 使用場景：評估/比較 LM 與翻譯模型、調參與早停、監控過擬合/資料漂移。

21. RMSE(Root mean squared error)


公式與計算

。給定實際值 $\{y_i\}_{i=1}^n$ 與預測值 $\{\hat{y}_i\}_{i=1}^n$ ，

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2, \quad RMSE = \sqrt{MSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

- RMSE 主要用於「回歸」（連續值預測），不是單純判斷對錯的分類指標。
- 連續目標的模型評估：房價預測、需求預測、溫度預測等。

22. ROC Curve(Receiver Operating Characteristic Curve)



- 橫軸：假陽性率（FPR）代表把負例誤認為正例的比例，理解為「代價」。
- 縱軸：真陽性率（TPR，也就是 Recall/召回率），代表把正例正確抓到的比例，理解為「收益」。
- 因此，ROC 圖是「收益-代價」曲線：調整分類閾值時，模型在抓到更多正例（收益）與造成更多誤報（代價）之間的權衡。
- 越靠近左上角、越明顯向左上彎曲，表示在相同的誤報代價下能取得更高的召回率，性能更佳。

23. AUC(Area Under the Curve)

- AUC 就是「隨機挑一個正樣本與一個負樣本，模型給正樣本更高分數的機率」。
- 因此，AUC 衡量的是模型的整體排序能力（discrimination/ranking）。

- 取值範圍：0.5~1.0（二分類、分數單調時）。
- 0.5：無鑑別力，等於擲硬幣。
- 0.7~0.8：尚可。
- 0.8~0.9：良好。
- ≥ 0.9 ：極佳。
- 小於 0.5 通常表示方向反了（顛倒預測即可改善）。

24. P-R Curve(Precision / Recall curve)

- 理想情況：曲線越靠近右上角越好；等價地，P-R AUC（曲線下面積）越大越好，代表在高召回下仍能維持高精確率。
- 資訊檢索/搜尋引擎：在海量文件中找少量相關文檔。
- 異常／欺詐偵測、醫療罕見病篩檢：正樣本非常稀少。
- 這些情境常需在「提高召回不漏掉正例」與「保持精確避免誤報」間權衡，P-R 曲線能直接呈現此權衡。

25. LogLoss

- 用途：機率輸出的分類模型。懲罰錯誤且過度自信的機率預測。
- 公式：Binary LogLoss = $-\left[y \cdot \log(p) + (1-y) \cdot \log(1-p)\right]$ 的平均。
- 範圍： ≥ 0 ，越低越好。
- 解讀：關注機率標定與不確定性。
- 局限：僅適用分類。對極端機率敏感。

26. Weighted Quantile Loss(wQL)

- 用途：時間序列分位數或機率式預測（如 P10/P50/P90）。
- 核心：對每個分位數 q 計算 pinball loss，再依權重加權平均。
- 單一分位數損失： $L_q(y, \hat{y}_q) = \max(q \cdot (y - \hat{f}), (q-1) \cdot (y - \hat{f}))$ 。
- 範圍： ≥ 0 ，越低越好。
- 解讀：同時評估多分位數的校準與覆蓋。與不確定性預測契合。
- 局限：需模型輸出分位數。權重設定會影響結果。
- 與時間序列：機率式預測的首選指標之一（如 Amazon Forecast 使用）。

27. Inference Latency

- 用途：系統效能指標。度量單次請求從送達到回應的時間。
- 量測：P50/P90/P99 延遲，平均延遲。
- 解讀：越低越好。關乎服務體驗與吞吐。
- 局限：不反映預測正確性。

28. Concept drift

- 定義：隨著時間變化，數據的統計特性發生變化的現象，這可能導致機器學習模型性能下降，因為模型基於舊數據訓練的假設不再適用。當原本的模式或規律不再適用時，模型的預測能力就會下降，就需要調整或重新訓練模型。
- 使用場景：在金融詐騙檢測、醫療診斷、自動駕駛等應用中，隨著時間的推移，數據分佈可能會變化，這要求機器學習系統具備檢測和適應概念漂移的能力，以保持預測準確性，常用方法包括定期重新訓練模型、使用增量學習等。

29. One-hot

- 定義：編碼是一種將分類變量轉換為數值型數據的技術，通過為每個類別創建二進制特徵來表示，確保模型能夠理解類別資訊，而不引入不必要的順序關係。

- 白話：就像為每個類別貼上一個獨特的“標籤”，每個標籤只有一個位置是 1，其他都是 0，使得計算機能夠輕鬆辨識每個類別。
- 使用場景：適合用於需要對分類變量進行機器學習模型訓練的情況，例如文本分類、圖像識別及推薦系統，特別是當類別之間沒有任何內在順序時。

30. Feature splitting

- 定義：將複合或序列型欄位（如時間戳、地址、字串）拆成多個原子特徵，以更精確表徵模式並避免混雜。
- 使用場景：日期拆年/月/週期；字串分詞；類別階層拆層級；多值欄位展開成指示變數。Stunning

31. Standardized distribution

- 定義：對 X 做 Z 標準化 $Z=(X-\mu)/\sigma$ ，使分佈均值 0、方差 1；形狀(偏態/峰度)不變。
- 白話：把數據平移與縮放到同一尺標，便於公平比較。
- 使用場景：特徵標準化、KNN/SVM/K-means、梯度收斂、 Z 分數異常偵測、統計檢定。

32. Label Encoding

- 定義：是一種將類別變量轉換為數值型數據的方法，通過為每個類別分配一個唯一的整數值，以便機器學習模型能夠理解和處理這些類別特徵。
- 使用場景：適合在類別之間存在某種順序或關聯的情況，例如教育等級（初中、高中、大學）或等級標籤（低、中、高），當然也適用於許多其他機器學習模型中的分類特徵。

33. Padding

- 定義：是在處理序列數據（如文本或時間序列）時，為了保持數據的統一長度而添加額外元素的過程。這些元素通常是零或某個特定值，以便讓所有序列能夠在同一批次中進行處理。
- 使用場景：適合用於自然語言處理（NLP）和序列模型（如 RNN 和 LSTM），在這些模型中，序列可能有不同的長度，因此需要使用 Padding 來確保批量處理時的數據形狀一致，確保高效計算。

34. Hyperband

- 概念：先給許多超參數組合少量資源（如少量 epoch/資料），快速篩掉差的；把資源集中到少數表現佳者。
- 優點：在單次訓練昂貴時，計算時間最低；自動分配資源；天然支援早停。
- 何時用：資料大、單次試驗成本高；模型隨訓練資源增加而單調改進。

35. Grid search

- 概念：對每個超參數劃定網格，窮舉所有組合。
- 優點：簡單、可重現。
- 缺點：計算爆炸，高維下效率極低；多浪費在不重要的維度。
- 何時用：超參數很少且範圍小，或做小型掃描建立直覺。

36. Bayesian optimization

- 概念：以代理模型（常見 Gaussian Process/TPE）擬合「超參數→效能」關係，選擇下一個最有價值的點（探索/利用折衷）。
- 優點：試驗次數少、樣本效率高；適合連續超參數。
- 缺點：每次試驗通常需完整訓練；在單次成本很高時，總時間可能大於 Hyperband。
- 何時用：試驗可完整訓練、搜尋空間中等維度、需要穩健收斂。

37. Random search

- 概念：在定義範圍內隨機抽樣。
 - 優點：實作簡單；在高維時常優於 Grid；易並行。
 - 缺點：樣本效率一般；無自適應導引。
 - 何時用：快速基線、資源可並行、對搜尋空間缺少先驗。
-

38. Shadow testing (影子測試)

- 定義：複製線上請求給「新模型影子變體」，不回覆用戶，只記錄與比較指標。
- 目標：在零風險前提下，用真實流量評估新模型的延遲、錯誤率與精度。
- 要點：
 - 生產回覆仍由舊模型提供。
 - 影子只接收同份請求，回應被丟棄。
 - 比對：離線標記或延遲到達標記，用於計算 A/B 指標差異。
 - 適用：上線前最後驗證、效能與資源規模評估、資料特性變動風險高時。

39. Blue/green deployments (藍綠部署)

- 定義：同時維持兩套可用版本 (Blue=現行、Green=新)。逐步把真實流量切到新版本，驗證穩定後再完全切換。
- 兩種常見策略：
 - Canary：先導少量 (如 1 - 10%) 流量到新版本，觀察指標再擴大。
 - All-at-once：一次性全量切換，僅適用把握度高或容忍短暫風險的情境。
- 目標：最小化停機與回滾時間，同時在真實環境逐步驗證新版本。
- 適用：新模型已通過影子或離線驗證，需要實際承載部分或全部用戶的最終切換階段。

40. rolling deployment

- 定義：逐批 (波次) 以新版本替換舊實例，期間保留部分容量與流量，經健康檢查；異常自動回滾。
- 白話：一台台換新、不停機；不穩就撤回。
- 使用場景：SageMaker 端點、EC2 自動調整、Kubernetes 等需連續交付、容量受限、漸進驗證與風險控制。

AWS服務簡述

➤ IAM User

- 人或程式的長期身分。
- 長期認證憑證：密碼、Access keys。
- 給人或固定程式使用。
- 本身不含權限，需透過附掛 Policies 或從 Groups 繼承。

➤ IAM Role

- 可被「扮演」的臨時身分（含信任策略）。
- 無長期憑證；被「AssumeRole」後取得臨時憑證（STS）。
- 兩種策略：Trust policy（誰能扮演）+Permission policies（能做什麼）。

➤ IAM Group

- 多位使用者的集合，用來批量套用政策。
- 只包含 Users；不可嵌套群組、不可直接登入。
- 將 Policies 掛在 Group 以一次影響多位 User。
- 不能附加到服務資源（如 Notebook）。

➤ IAM Policy

- 多位使用者的集合，用來批量套用政策。
 - JSON 規則集：Action、Resource、Effect、Condition。
 - 類型：AWS 托管、客製化；可附掛到 User / Group / Role。
-

➤ Amazon EBS (Elastic Block Store)

- 定義：EBS 是與 EC2 相連的持久區塊儲存；支援卷類型如 gp2/gp3（通用）、io1/io2（高IOPS），可做快照備份與還原。
- 白話：把 EC2 想成電腦，EBS 就是可插拔的硬碟，關機資料不丟，還能拍照（快照）回復。
- 使用場景：ML 資料集與特徵庫、訓練中間產物、模型與權重存放、實驗可回溯快照、需要高 IOPS 的資料載入與推論磁碟。

➤ Amazon EFS(Elastic File System)

- 定義：EFS 為 AWS 全託管、可擴展的 NFS 網路檔案系統，支援多個 EC2 同時掛載，容量自動伸縮，按用量計費。
- 白話：就像雲端共享硬碟，多台機器可同時讀寫同一資料夾，空間會自動增減。
- 使用場景（ML）：多人協作原始碼與資料共享、分散式訓練共用資料集、集中存放模型版本與檔案、ECS/EKS 多容器共同讀取模型做推論。

➤ Amazon FSx

- 定義：FSx 是受管檔案服務，含 FSx for Windows（SMB）與 FSx for Lustre（HPC 級高效能）。
- 白話：免自建檔案伺服器；Lustre 像超高速共享資料夾，專治大量並行讀寫。
- 使用場景（ML）：分散式訓練共享資料集；SageMaker 透過 FSx for Lustre 加速載入 S3 資料；高吞吐特徵生成、批量訓練/評估；Windows 應用需 SMB 共享。

➤ Amazon ElastiCache (Redis OSS) cluster

- 定義：相容 Redis OSS 的受管記憶體資料庫，支援分片(Cluster Mode)、多AZ複寫與自動故障移轉，微秒級延遲。
 - 白話：把常用資料放記憶體的「快取+暫存庫」，超快、可水平擴展。
 - 使用場景：會話/排行、Rate limit、佇列、ML特徵/推論結果快取、特徵線上存取。
-

➤ AWS Secrets Manager

- 定義：受管機密服務，安全儲存/加密/版本化/取用秘鑰與密碼，支援自動輪替 (Lambda)、細粒度IAM與審計。
- 使用場景：DB密碼輪替、API金鑰管理、與RDS/ECS/EKS/Lambda整合。

➤ AWS Systems Manager Parameter Store

- 定義：受管參數儲存，支援明文/加密(KMS)、版本化、層級命名、IAM控管與審計，並與多項AWS服務整合。
 - 白話：把設定與密鑰放雲端保險箱，程式按權限臨時領用，不寫進程式碼。
 - 使用場景：環境變數、DB連線字串、API金鑰、跨環境配置、CI/CD 部署時注入機密。
-

➤ Amazon S3

- S3 Standard：高頻存取，毫秒級延遲，跨多 AZ，99.999999999% 耐久度。
- S3 Intelligent-Tiering：自動分層，依存取模式在數個層級間移動以降成本。
- S3 Standard-IA：低頻存取，多 AZ；有最短儲存期與取回費。
- S3 One Zone-IA：低頻存取，單一 AZ；成本更低，風險較高。
- S3 Glacier Instant Retrieval：很少讀但需即時取回的物件；多 AZ。
- S3 Glacier Deep Archive：最低成本，長期封存；取回需數小時。
- S3 Express One Zone：單 AZ、超低延遲與高每秒請求量的熱資料（目錄/索引/臨時中繼）。

➤ S3 Gateway Endpoint

- 定義：VPC 的 Gateway 端點，經路由表私通 S3，免 IGW/NAT，並以端點/桶策略細粒度控權。
 - 白話：給私有子網一條直達 S3 的內線，不走公網更安全也省事。
 - 使用場景：無公網存取、降低 NAT 成本、資料外洩防護、合規隔離。
-

➤ Amazon Kinesis Data Streams

- 定義：可擴展的即時串流服務；高吞吐、順序保留 (Shards)、多消費者並行；整合 Lambda、S3、SageMaker。
- 使用場景：線上推論觸發（推薦/欺詐）；即時特徵管線；模型與資料品質監控（漂移/延遲）；點擊流與IoT收集。

➤ Amazon Kinesis Data Firehose

- 定義：全託管串流傳送服務，自動擴展與緩衝，將資料可靠寫入 S3、Redshift、OpenSearch 等，支援轉換/壓縮/加密。
- 使用場景 (ML)：即時事件落地到 S3 供特徵計算與訓練、寫入 Redshift 做近即時分析、模型監控日誌集中化。
- 不支援把「已存在 S3 的批次原始資料」做整批 ETL。

➤ Streams V.S Firehose

面向	Kinesis Data Streams (KDS)	Kinesis Data Firehose
角色定位	事件流平台，讓多個「即時」消費端各自讀取與處理	近即時匯入管道，將資料自動落地到目的端
管理負擔	較高，需要設計消費者、監控與調整	較低，開箱即用的資料落地服務
使用場景	需要毫秒～秒級即時處理、多個獨立下游、可重放與順序性	目標是把串流資料「穩定、低維運」地落到 S3/Redshift/OpenSearch，接受分鐘級延遲並想要內建壓縮與格式轉換

- 兩者可串接：先進 Kinesis Data Streams 即時處理，旁路交給 Kinesis Data Firehose 做批量落地。
- Kinesis Data Streams處理對外資料後，再交由Kinesis Data Firehose放到AWS上的各處服務。

➤ Amazon Kinesis Data Analytics

- 定義：託管即時分析服務；對接 Kinesis Data Streams/Firehose，使用 SQL 或 Apache Flink 做視窗聚合、過濾、函數運算。
- 白話：像流水線上的「分析員」，資料邊流動邊計算，產生即時指標再丟往下游。
- 使用場景（ML）：
 - ◆ 即時特徵提取（滑動視窗、會話聚合）
 - ◆ 線上異常偵測/打分前處理
 - ◆ 模型監控指標聚合（延遲、漂移）
 - ◆ 事件過濾與增 enrich 後供推論

➤ AWS DataSync Task

- 定義：是具體的資料遷移工作單元，定義來源與目標位置（本地↔S3/EFS/FSx），並設定傳輸選項（頻寬限制、資料驗證、過濾規則、排程），以自動化高速同步/搬移資料。
- 使用場景：
 - ◆ 跨環境遷移：定期把本地資料同步到 S3
 - ◆ 備份/還原：排程自動備份檔案到雲端
 - ◆ 混合雲：維持本地與 EFS/FSx 檔案系統一致同步

➤ Amazon Simple Queue Service (SQS)

- 定義：是分散式消息佇列服務，用於解耦應用元件並可靠傳遞消息，提供可擴展、高可用的非同步通訊；支援 Standard（高吞吐、至少一次）與 FIFO（先入先出、恰好一次順序）兩種佇列類型。
- 使用場景：
 - ◆ 微服務間通訊與任務解耦
 - ◆ 非同步處理（訂單、影像轉碼）
 - ◆ 流量削峰填谷、緩衝高負載

➤ Amazon MSK Flink (Amazon Managed Service for Apache Flink)

- 定義：基於 Apache Flink 提供流處理能力，與 Amazon Managed Streaming for Apache Kafka (MSK) 緊密集成。它使開發人員能夠輕鬆構建、運行和擴展流式應用程序，並提供高可用性和可靠性。

- 使用場景：適合需要即時數據處理和分析的應用場景，如即時數據流分析、事件調度和反應式應用程序。特別是在金融監控、社交媒體數據分析和物聯網設備管理等領域，Amazon MSK Flink 提供了強大的支持，使得開發者能夠快速應對變化的數據流，並實現更高的業務靈活性。這項服務的自動擴展能力也有助於處理不同負載的數據流，滿足動態業務需求。
-

➤ Amazon Neptune

- 定義：AWS全託管圖形資料庫，支援Property Graph (Gremlin/openCypher) 與RDF (SPARQL)，ACID、高可用、低延遲圖遍歷。
 - 白話：把實體與關係當「節點/邊」存，能很快找到誰跟誰有關、關係多遠。
 - 使用場景：知識圖譜、詐欺關聯偵測、社群/推薦、主數據關聯、網路拓撲。
-

➤ Amazon EMR(Elastic Map Reduce)

- 定義：託管的大數據處理平台，支援 Spark、Hadoop、Hive、Presto 等，彈性叢集/Serverless，與 S3/Glue/IAM 整合。
 - 使用場景 (ML)：特徵工程與ETL、超大資料集的分散式訓練前處理、離線批量評估、模型產物寫回 S3 與資料湖加速 (EMRFS、Hudi/Iceberg)。
-

➤ Amazon OpenSearch Service

- 定義：託管的搜尋與分析引擎，基於開源 OpenSearch (由 Elasticsearch、Kibana 衍生)。提供即時索引與查詢、可視化儀表板、日誌/指標分析與應用監控，支援大規模資料處理與高可用部署。
 - 使用場景：
 - ◆ 日誌集中化與故障排查 (App/Server)
 - ◆ 網站/APP 全文搜尋與過濾排序
 - ◆ 即時商業指標與可觀測性儀表板
-

➤ AWS Marketplace

- 定義：AWS 第三方軟體/資料/模型市集，支援 AMI/容器/SaaS/SageMaker，整合計費/授權與私有報價。
 - 白話：像雲端「應用商店」，點一下就能在 AWS 部署並付費。
-

➤ Amazon SageMaker

■ SageMaker Studio

- ◆ 定義：雲端一站式 ML IDE，整合開發/訓練/部署/監控全流程，含 Notebook、JupyterLab、調參/除錯與監控視覺工具。
- ◆ 使用場景：
 - 實驗→Notebook/HPO
 - 除錯→Profiler/Debugger
 - 部署→Endpoint
 - 監控→Model Monitor/Lineage

■ SageMaker Ground Truth

- ◆ 定義：受管資料標注服務，整合私有/公開標注團隊、主動學習減標注量，內建多層品質驗證。
- ◆ 白話：把標注「外包」給人力與機器協作；半自動預測先標，人工只改錯，且有品質控制。
- ◆ 使用場景：新專案快速建立高品質資料集；迭代補標與錯誤修正；透過主動學習挑難例提升模型，品質提升→模型更聰明。

■ SageMaker Data Wrangler

- ◆ 定義：SageMaker 的視覺化資料準備工具；連接多種資料源，提供數百種轉換與特徵工程，並可匯出至 Processing/Training Pipeline。
- ◆ 使用場景：特徵工程與資料清洗、類別編碼與缺值處理、採樣與偏態修正、快速產生可重複的 ML 資料處理管道並輸出到 S3/訓練作業。

■ SageMaker Debugger

- ◆ 定義：訓練監控與偵錯工具，能即時擷取訓練張量/指標，套用規則自動偵測問題（如梯度消失/爆炸、過擬合、資料偏差），並提供可視化與警示。
- ◆ 使用場景：
 - 即時發現訓練異常與提前停訓
 - 追蹤資源利用率，優化成本/效能
 - 分析梯度/權重變化，提升模型可解釋性

■ SageMaker Model Monitor

- ◆ 定義：監控部署端點的資料與效能漂移；支援特徵分布、品質、延遲等指標，異常告警與報表。
- ◆ 上線後持續監控、自動異常告警、觸發重訓/回滾、合規審計與漂移報告。

■ 使用場景(Debugger V.S Model Monitor)

面向	SageMaker Debugger	SageMaker Model Monitor
目標	偵測訓練過程異常與效能瓶頸	偵測上線後資料/模型品質與漂移
時機	訓練中與訓練後分析；亦含訓練資源剖析	佈署後長期監控（Real-time endpoint 或批次）
觀測對象	爆炸/消失梯度、過擬合、學不動、資源閒置或飽和	資料漂移、概念漂移、特徵缺失、異常值、偏差指標惡化、模型品質下降

- ◆ 想在訓練當下找出學習或資源瓶頸並縮短收斂時間 → 用 Debugger。
- ◆ 想在上線期間持續守住資料/模型品質與合規，偵測漂移與偏差 → 用 Model Monitor。
 - 端到端做法：訓練期用 Debugger
 - 調校與剖析；佈署後用 Model Monitor 建基線與排程監控，觸發告警與回訓流程。

■ SageMaker Feature Store

- ◆ 定義（技術關鍵詞）：託管的特徵儲存與共享服務，提供線上/離線存取、一致性與時間版控，支援低延遲查詢與批處理整合。
- ◆ 使用場景（具體ML案例）：即時推薦/詐欺偵測低延遲取特徵；離線訓練用快照重現；跨團隊避免重複計算，保障線上/離線特徵一致。

■ SageMaker Clarify

- ◆ 定義：偏見檢測+可解釋性工具：訓練與部署前後分析偏見指標、特徵重要性、預測歸因（SHAP、PDP）。
- ◆ 白話：像決策「翻譯機」，把黑盒子決策變成人話報告，指出哪個特徵影響最大、有無不公平。
- ◆ 使用場景：GDPR/合規報表、金融信貸公平性審查、醫療模型除錯與漂移後原因追蹤（訓練前審核、上線後監控）。

■ SageMaker Canvas

- ◆ 定義：面向業務分析師的無程式碼 ML 工具，透過視覺化介面上傳資料、建模與預測，並可與 SageMaker 協作。
- ◆ 白話：像「拖放式 ML 神器」，類似用 Excel 操作，免寫程式就能預測關鍵指標。
- ◆ 使用場景：快速預測（銷售額、流失風險）、跨部門協作（共享模型與預測）、資料探索（自動特徵與重要度分析）。

■ SageMaker Notebooks

- ◆ 定義：託管的 Jupyter 筆記本環境；預裝主流 ML/深度學習框架，一鍵啟動/暫停、彈性調整算力，與 SageMaker 資料準備、訓練、部署與實驗追蹤深度整合。
- ◆ 使用場景：數據探索與EDA、原型建模、啟動訓練作業、批/即時推論測試、記錄實驗、教學與團隊分享。
- ◆ 注意：IAM Group不能掛在SageMaker Notebooks上，SageMaker Notebooks只能掛載IAM role。

■ SageMaker Pipelines

- ◆ 定義：SageMaker 的 ML 工作流程自動化與無伺服器編排服務；以宣告式管道定義資料處理→訓練→評估→部署；強調可重現性（版本化/參數化）與與 SageMaker/CI 工具深度整合。
- ◆ 使用場景：
 - 模型 CI/CD（自動化訓練與部署）
 - 自動化評估與門檻把關（品質閘）
 - 上線後模型監控觸發再訓練

■ SageMaker Experiments

- ◆ 定義：SageMaker 的實驗追蹤，以 Experiment/Trial/Component 記錄與版本化超參、評估指標、工件與血緣，支援搜尋、比較、審計。
- ◆ 使用場景：超參搜索與多模型對比、資料/程式變更追溯、與Studio/Pipelines/Model Registry 串接。

■ SageMaker Autopilot

- ◆ 定義：受管 AutoML；自動化特徵工程、模型選擇/訓練/超參調優與排名，支援 tabular data 的分類/回歸。
- ◆ 白話：像「自動建模機器人」，丟資料與目標欄，它就幫你試很多模型並挑最優。
- ◆ 使用場景：快速 PoC、缺乏 ML 經驗團隊上線基礎模型、建立特徵工程與模型選型基準。

■ SageMaker Neo

- ◆ 定義：AWS SageMaker Neo 是一個為機器學習模型提供優化推理的服務，支持將訓練好的模型轉換為可在多種硬體平台（如雲端和邊緣設備）上高效運行的格式。它實現了模型壓縮及編譯，從而降低延遲並提升推理效能。

- ◆ 使用場景：
 - 邊緣計算：如自動駕駛汽車、智慧型攝影機等，需在邊緣設備上快速進行推理。
 - 物聯網（IoT）：在分佈式設備上運行機器學習推理，解決延遲和帶寬問題。
 - 高效雲端推理：即使在大規模用戶請求下，仍能快速響應的應用如聊天機器人和推薦系統。

■ SageMaker JumpStart

- ◆ 定義：幫助用戶快速啟動和部署預先構建的機器學習模型和解決方案。它提供不同行業和應用領域的模型模板，並包含示例Notebook，以加速模型的構建和實現。
- ◆ 使用場景：
 - 初學者：對於剛入門的數據科學家和開發者，提供易於使用的範例和預配置的模型，幫助他們快速學習和實踐。
 - 企業快速實施：幫助企業在特定業務問題（如預測分析、圖像識別、自然語言處理）上迅速部署解決方案，縮短開發時間。
 - 原型開發：加速模型原型的建立，便於驗證商業假設或進行概念測試。

■ SageMaker managed warm pools

- ◆ 定義：SageMaker 的冷啟動解決方案，能夠在提升模型推論性能的同時，自動管理預熱實例池，當有請求時立即提供可用的優化實例。
- ◆ 使用場景：適合波動性請求的應用，如電子商務推薦系統、社交媒體內容生成或任何需快速反應的推論任務。透過減少冷啟動延遲，確保用戶體驗流暢。

■ SageMaker Training Compiler

- ◆ 定義：自動化的訓練優化工具，專為深度學習框架（如 TensorFlow 和 PyTorch）設計，能自動轉換並優化模型，以提升訓練性能和效率。
- ◆ 使用場景：適合大型深度學習模型的訓練，如計算機視覺、自然語言處理等任務，特別是當計算資源有限時，能更好地利用 GPU/機器學習基礎架構。

■ SageMaker distributed data parallelism (SMDDP)

- ◆ 定義：分佈式數據並行訓練技術，能在多個計算節點上一起訓練深度學習模型，並有效地同步權重更新，縮短訓練時間。
- ◆ 使用場景：適合大型數據集和計算複雜的模型訓練，如計算機視覺或語言模型等，特別在 GPUs 或多機器環境中，能有效減少訓練時間，提升資源使用效率。

■ SageMaker ML Lineage Tracking

- ◆ 定義：幫助用戶跟蹤和管理機器學習工作流中的所有資源和變更，包括數據集、訓練模型和依賴關係，以增強模型的可追溯性和透明度。
- ◆ 使用場景：適合在高合規性環境中工作，如金融或醫療行業，使用者可以追蹤數據和模型的來源，以應對合規要求和確保模型的可靠性。此外，這也有助於故障排查和模型的持續改進，提高整體開發和運營效率。

■ SageMaker Asynchronous Inference

- ◆ 定義：SageMaker 非同步推論用於長耗時預測（秒到分鐘），接收請求後排隊處理，結果輸出至 S3，並可透過回呼/通知取得結果。
- ◆ 使用場景：批次預測、影像生成/影片處理、超大模型或前處理耗時任務；不需即時回應但需確保結果可靠與可追蹤。

■ SageMaker Real-time Inference

- ◆ 定義：SageMaker 即時推論提供長駐端點，透過自動/手動擴縮，毫秒到秒級延遲回應

請求，支援多模型端點（MME）、模型監控與雲端日誌/指標整合。

- ◆ 使用場景：互動式應用（即時推薦/欺詐偵測/聊天機器人）、低延遲API、峰值可擴縮、需要即時回饋的ML服務。

■ SageMaker Serverless Inference

- ◆ 定義：無伺服器推論，依請求自動配置/縮回計算資源，按用量計費，適合間歇或不可預測流量，免管理基礎設施。
- ◆ 使用場景：低至中流量API、原型/實驗、尖峰不固定的應用、成本敏感的推論工作。

■ SageMaker Inference Recommender

- ◆ 定義：SageMaker 的自動化基準測試與選型工具，針對模型與流量特性，評估不同實例/容器/並行度設定，產生最佳化推論配置與吞吐/延遲報告。
- ◆ 使用場景：
 - 上線前選擇 Real-time/Serverless/Async 的端點機型與佈署參數
 - 性能調優與成本壓測
 - 模型升版後快速回歸基準比較

■ SageMaker endpoint

- ◆ 定義：SageMaker Endpoint 是用於部署訓練好的機器學習模型的服務，提供實時推論能力，支援高可用性與自動擴展。
- ◆ 使用場景：適合需要即時反應的應用，如網上商店的商品推薦、聊天機器人、自動化客服，或任何需要即時預測的場景，透過 API 進行即時推論請求。

■ SageMaker Batch Transform

- ◆ 定義：為離線批次推論，免部署端點；由 S3 讀取，臨時叢集並行運算，結果寫回 S3。
- ◆ 使用場景：一次性/排程大量預測、成本敏感、不需低延遲；超大檔處理、歷史回填、資料湖特徵/標註生成。

■ SageMaker Edge Manager

- ◆ 定義：邊緣模型生命週期管理；優化(編譯/量化)、打包簽署、部署版本；Edge Agent 監控與資料擷取。
- ◆ 使用場景：IoT/製造視覺、零售POS、醫療；離線低延遲、艦隊管理、漂移偵測。

■ SageMaker Seq2Seq

- ◆ 定義：內建的序列到序列（seq2seq）深度學習演算法（基於 MXNet/Sockeye），採 Encoder - Decoder + Attention，支援教師強制與 beam search 解碼，用於將輸入序列對映為輸出序列。
- ◆ 使用場景：機器翻譯（NMT）、摘要/標題生成、語句改寫與糾錯、對話回覆生成、程式碼註解生成等需要「序列→序列」的任務。

■ SageMaker Model Registry

- ◆ 定義：SageMaker Model Registry 是一個集中式的模型管理服務，用於記錄、版本控制和管理機器學習模型，支持多個階段（如開發、測試、部署）和元數據跟蹤。
 - ◆ 使用場景：適合企業需要管理多個模型版本的場景，如測試新模型或回溯至舊版本，支援模型生命週期管理，提高協作效率，特別在大型團隊與多樣性模型的情況下。
 - ◆ Model Registry collection => SageMaker 模型登錄的 Collections，用於將相關模型分組、階層化管理，提升可發現性
-

➤ Amazon EventBridge

- 定義：無伺服器事件匯流排，整合 AWS/自訂/SaaS 來源，透過規則路由至多目標（Lambda、Step Functions 等），實現解耦與可擴展事件驅動架構。
 - 白話：像「事件快遞中心」，收件辨識後送到正確部門處理。
 - 使用場景：
 - ◆ S3 新資料觸發訓練
 - ◆ 訓練完成觸發評估/部署
 - ◆ CloudWatch 警報觸發異常處理
-

➤ AWS IoT Greengrass

- 定義：AWS IoT Greengrass 是一項邊緣計算服務，允許設備在本地執行業務邏輯，並與 AWS 雲端服務互通。它使 IoT 設備能夠在無需依賴雲端的情況下，交互和處理數據，從而提高了反應速度和減少了數據延遲。
 - 使用場景：
 - ◆ 智慧農業：基於感測器數據在本地自動調整灌溉系統或氣候控制，而無需連接雲端，確保及時反應。
 - ◆ 工業自動化：工廠內部設備在本地執行監控和預測維護，減少對連通性和延遲的依賴，提升作業效率。
 - ◆ 智慧城市：進行即時數據處理和反應，例如交通信號燈系統自動調整，以改善交通流量，提升市民的生活品質。
-

➤ Elastic Fabric Adapter (EFA)

- 定義：高吞吐、低延遲網路介面，為 HPC 與大規模分散式 ML 訓練設計，繞過 OS 直通網路硬體（OS bypass）。
 - 白話：像「ML/GPU 叢集的高速公路」，節點溝通更快更穩，訓練更有效率。
 - 使用場景：分散式深度學習（SageMaker 多節點、Horovod）、MPI 並行運算、HPC 模擬與科學計算。
-

➤ Amazon Mechanical Turk

- 定義：眾包平台；發布 HITs（Human Intelligence Tasks）給全球工作者，執行資料處理/標注與需人判斷之任務；內建審核與支付流程。
 - 使用場景：ML資料標注（影像分類/邊界框/語音轉寫）；內容審核與品質評分；問卷調查/人機比較；長尾資料補標與驗證。
-

➤ AWS Glue

- 定義：無伺服器 ETL/整合服務；含資料目錄、爬網器、作業（Spark/SQL/Python）、工作流程與撰寫器，支援批次與近即時。
- 使用場景：資料湖建置（S3+Glue Data Catalog）、跨源ETL到Redshift、特徵前置清洗、串接Kinesis做近即時處理、生成表給 Athena 查詢。

■ AWS Glue Studio

- ◆ 定義：Glue 的可視化 ETL 介面；以拖放建立/排程 Glue 作業與流程，生成 Spark/SQL 程式碼，支援批次與串接資料目錄。

- ◆ 使用場景：快速做 S3→Redshift 清洗/載入、將特徵表轉換供 Athena/Feature Store、把多源資料整併成訓練集。

■ AWS Glue Data Quality

- ◆ 定義：Glue 內建資料品質檢測；以規則庫（內建/自訂）、DQDL 定義約束（constraints），自動評估集並生成報告，支援排程重複監控與漂移偵測。
- ◆ 使用場景：特徵工程前驗證、ETL 生產管線即時阻斷髒數據、每日表監控與合規報告、與 SageMaker Pipelines 整合啟停流程。

■ AWS Glue DataBrew

- ◆ 定義：無程式碼、可視化資料準備工具；內建250+轉換，與 S3、Redshift、Athena 整合，批次輸出到多種目的地。
- ◆ 使用場景：模型前的資料清洗/特徵前處理、分析師自助備數據、快速原型小型 ETL、產出表給 Athena/Redshift。

■ AWS Glue FindMatches

- ◆ 定義：是一個用於自動化資料去重和匹配的服務，利用機器學習算法來識別和合併相似但不完全相同的資料記錄，以清理和完善資料集。
- ◆ 使用場景：適合用於客戶資料、產品清單等需要整合多個來源的場景，特別是在面對多種形式的數據時，可以有效降低手動清洗數據的成本，提高數據準確性，常見於電子商務、行銷資料管理及合併不同數據庫等應用。

■ AWS Glue Crawler

- ◆ 定義：是一個自動化工具，用於掃描資料來源（如 S3、RDS、Redshift 等），自動識別資料結構（schema），並將其添加到 AWS Glue Data Catalog 中。
 - ◆ 使用場景：適合用於 ETL 流程，快速發現和整理不同資料來源的結構，提升數據治理與資料倉儲的效率，特別是在處理大型或多樣化的數據集時。
-

➤ Amazon Athena

- 定義：無伺服器互動式查詢服務，使用標準 SQL 分析 S3 資料；與 Glue Data Catalog 整合，按掃描資料量計費。
 - 白話：像「SQL 版的 S3 搜尋引擎」，不建資料庫就能直接查 S3。
 - 使用場景：資料湖探索、特徵庫快查、訓練結果與日誌分析、建立臨時表供可視化/下游 ML。
-

➤ Amazon Redshift

- 定義：是一種完全受管理的數據倉儲服務，設計用於高速查詢和分析大量資料，支援 SQL 查詢和數據分析，並提供縱向擴展能力。
- 使用場景：適合需要快速查詢和分析的應用，如商業智能報告、數據挖掘和分析、實時網站分析，以及任何需要從大數據中快速提取見解的情況，特別是在分析資料不斷增長的環境下。

■ Amazon Redshift Spectrum

- ◆ 定義：是一個擴展 Amazon Redshift 的功能，允許用戶直接查詢存儲在 Amazon S3 中的資料，而無需將資料加載到 Redshift 中，支持即時分析和聯合查詢。
- ◆ 白話：像一個「橋樑」，讓你能夠跨越 S3 和 Redshift 之間的數據，無需搬家就能直接查詢和分析 S3 中的資料。

- ◆ 使用場景：適合處理大型數據集、實時資料分析和處理異構數據來源時，特別能提高查詢效率並降低數據存儲成本，常用於分析日誌資料、事件數據或其他大量存儲在 S3 的資料。
-

➤ AWS Managed AI Services

- 定義：AWS 預訓練 AI API，開箱即用、免模型訓練；涵蓋影像/影片 (Rekognition)、NLP (Comprehend)、語音轉文字 (Transcribe)、翻譯 (Translate)、聊天機器人 (Lex)、推薦 (Personalize) 等。
 - 白話：像「現成 AI 積木」，直接呼叫 API 就能完成辨圖、讀文、聽說與推薦。
 - 使用場景：內容審核與OCR、情緒/關鍵詞抽取、語音客服轉錄、跨語系服務、電商個人化推薦、快速為應用加上 AI 能力。
-

➤ Amazon Comprehend

- 定義：受管 NLP 服務；提供關鍵字/關聯、實體抽取、情感分析、語言偵測、主題建模；支援自訂分類器與自訂實體模型。
 - 白話：像「讀懂文字的AI」，自動看文章抓重點、找人名地名、判斷正負評。
 - 使用場景：客服工單情感/意圖分類、文件實體抽取 (PII遮罩)、評論洞察、醫療/法務文件剖析、建立標籤供搜尋與推薦。
 - Amazon Comprehend ImportModel API
 - ◆ 定義：是一項用於將自訂機器學習模型導入 Amazon Comprehend 的服務，讓用戶能夠集成自己的自然語言處理模型，以滿足特定需求。
 - ◆ 使用場景：適合需要特定領域詞彙或專有名詞的應用，例如醫療、法律或技術文件分析，能夠提升模型的準確性和相關性，滿足業務的特殊需求。
 - Named Entity Recognition (NER)
 - ◆ 定義：屬於 Amazon Comprehend 的實體抽取功能；以受管 NLP 模型從文字中偵測人名、地點、組織、時間、金額、PII 等實體，支援多語與自訂實體模型。
 - ◆ 使用場景：客服工單自動標註、文件中 PII 偵測與遮罩、法務/醫療文件關鍵實體抽取、建立搜尋與推薦的標籤。
 - Custom Entity Recognition
 - ◆ 定義：在 Amazon Comprehend 訓練自訂 NER 模型，從文字抽取領域特定實體；支援標註資料、字典 (entity lists)、自動調參與批量/即時推論。
 - ◆ 使用場景：法規/醫療術語抽取、電商商品屬性解析、工單中錯誤碼/設備型號標註，供搜尋、特徵工程與風險審核。
-

➤ Amazon Translate

- 定義：受管神經機器翻譯 (NMT) 服務；支援75+語言對，客製術語表或自訂翻譯模型，無伺服器、按使用計費。
- 使用場景：多語客服、網站與文件在地化、內容審核翻譯輔助、跨語言數據分析與報表。

➤ Amazon Transcribe

- 定義：受管自動語音辨識 (ASR) 服務，音訊轉文字；支援即時/批次、多語言/多聲道，話者分離，時間戳記，PII 偵測與遮罩，自訂詞彙與自訂語言/領域模型。
- 使用場景：客服通話轉錄與質檢、會議/採訪逐字稿、媒體字幕、語音筆記整理、作為後續

NLP（如情感分析、關鍵詞抽取）的前處理。

➤ Amazon Polly

- 定義：文字轉音訊；語多聲線，提供 Neural TTS（更自然）、標準語音，支援 SSML 控制語速/重音/停頓/發音，詞彙表與語音標籤。
- 使用場景：無障礙朗讀、語音介面/IVR、內容配音與旁白、IoT 裝置播報、聊天機器人回覆。

➤ Amazon Rekognition

- 定義：受管影像/影片分析服務；提供物體/場景偵測、臉部分析與比對、名人辨識、不當內容偵測、文字辨識（OCR）、臉部索引與搜尋。
- 使用場景：媒體自動標籤與內容審核、門禁與重返識別、安全監控告警、客流分析、OCR擷取做後續metadata/搜尋。

➤ Amazon Macie

- 定義：是一項完全管理的資訊安全服務，它利用機器學習和自然語言處理技術；自動識別、分類和保護 AWS 上的敏感數據，幫助企業維護數據安全和合規性。
- 使用場景：適合需要遵守資料隱私法規（如GDPR或CCPA）的企業、在數據安全方面有高要求的應用，能夠自動識別潛在的安全風險，並幫助企業採取行動來保護他們的數據。

➤ Amazon Lex

- 定義：受管對話機器人服務；整合 ASR+NLU，支援文字/語音、多輪對話、意圖與槽位填充，易佈署至Web/行動/訊息平台，並可接AWS後端。
- 使用場景：銀行/電商客服、IT/HR 助手、訂位/訂單查詢、IoT 語音控制、搭配 Connect 呼叫中心自動化。

➤ Amazon Personalize

- 定義：受管推薦系統；以協同過濾與語義搜尋建模，輸入互動/使用者/項目資料，輸出個人化推薦、相似項、重新排序與即時更新。
- 使用場景：電商商品推薦、媒體內容/播放清單、搜尋結果重排、推播/EDM 個人化。

➤ Amazon Textract

- 定義：受管文件理解與OCR服務；除文字辨識外，能解析表格、表單欄位與關聯，輸出結構化資料與信心分數，支援多頁PDF/掃描。
- 使用場景：發票/收據入帳、自動化合約與KYC文件擷取、保險理賠/醫療表單鍵入、檔案庫索引與搜尋。

➤ Amazon Kendra

- 定義：受管智慧企業搜尋；以NLP理解語意，跨多資料源透過連接器整合，支援自然語言查詢、FAQ匹配、答案精確定位。
- 使用場景：HR政策查詢、合規與法規檢索、客服知識庫QA、技術文件與內部Wiki搜尋。

➤ Amazon Augmented AI (A2I)

- 定義：受管人工審核服務；在 SageMaker/Rekognition/Textract 等流程中，依信心門檻自動觸發人工審查與修正。
 - 使用場景：KYC文件審核、內容審核邊界案例、醫療影像複核、模型驗證與資料標註。
-

➤ Amazon EC2(Elastic Compute Cloud)

■ Spot Instances

- ◆ 定義：Spot Instances 允許用戶在低於正常價格的情況下使用 Amazon EC2 的計算能

力，透過拍賣制度來獲得未使用的 EC2 資源。

- ◆ 使用場景：適合可以容忍中斷的應用，例如大數據處理、批量數據分析或測試環境，因為 AWS 可能隨時會終止這些實例以響應需求變化。

■ Reserved Instances

- ◆ 定義：允許用戶以較低的價格預訂 EC2 實例，通常適用於需要長期運行的工作負載，使用者提前支付一定的費用來鎖定資源。
- ◆ 使用場景：適合有穩定工作負載的長期運行應用，如資料庫伺服器或持續開發的應用程序，能節省成本並提高預測性。

■ On-Demand Instances

- ◆ 定義：允許用戶隨時按需使用 EC2 實例，按照實際使用的時間計費，無需長期承諾或提前支付。
- ◆ 使用場景：適合需要快速啟動的應用、開發和測試環境，或許可以接受偶爾高峰流量的應用，通常用於不確定需求的情況。

■ Dedicated Instances

- ◆ 定義：是專門為特定客戶分配的 EC2 實例，運行在專用的物理硬體上，以增加安全性和合規性。
 - ◆ 使用場景：適合有合規要求或希望將資源隔離的應用，常見於金融服務、醫療應用等需要高度安全和隱私的行業。
-

■ AWS Trainium instances

- ◆ 定義：是專為深度學習訓練打造的雲端加速晶片，強調高效能/低成本，原生支援 TensorFlow、PyTorch、XLA，並優化分散式訓練（EC2 Trn1）。
- ◆ 使用場景：
 - 大型自然語言模型訓練
 - 推薦系統深度網路
 - 高頻寬分散式訓練

■ AWS Inferentia instances

- ◆ 定義：是為深度學習推理打造的雲端加速晶片，著重高吞吐、低延遲；透過 Neuron SDK 部署 TensorFlow/PyTorch 模型，提供 EC2 Inf1/Inf2 實例。
 - ◆ 使用場景：
 - 即時預測服務（推薦、影像辨識）
 - 批量推論任務
 - 優化服務延遲與成本
-

➤ Amazon Lookout

- 定義：受管異常偵測系列：Lookout for Vision（影像瑕疵）、Equipment（感測器/設備故障）、Metrics（時序KPI異常）。
- 使用場景：產線缺陷檢驗（Vision）、機台預測性維護（Equipment）、營運/轉換率/金流異常偵測（Metrics）、SLA/流量突波告警。

➤ Amazon Fraud Detector

- 定義：受管詐欺偵測；以事件類型建模，結合預建模板與自訓模型，輸出風險分數與原因碼供規則決策。

- 使用場景：電商付款詐欺、帳戶註冊/登入濫用、促銷濫領與虛實交易風險控管。

➤ Amazon Q Business

- 定義：企業級生成式AI助理；以RAG整合企業資料源與存取權限，支援來源引證、Guardrails、細粒度授權與稽核。
- 使用場景：內部知識查詢、政策/流程問答、客服與IT自助、文件摘要與工作流程自動化。

➤ Amazon Q Apps

- 定義：自然語言生成式應用建構工具；整合企業資料源與權限控制，自動生成無程式碼輕量應用。
- 使用場景：內部數據可視化工具、簡易表單與報告生成、流程自動化小工具、跨系統資訊查詢介面。

➤ Amazon Q Developer

- 定義：開發者向生成式AI助理；支援程式碼生成、除錯、單測生成、重構、基於私有程式庫的RAG搜尋，整合IDE/CLI。
 - 使用場景：新功能腳手架、錯誤排查與修復、單元測試覆寫提升、PR 摘要與文件生成。
-

➤ AWS Elastic Container Registry(ECR)

- 定義：全託管容器映像倉庫；支援 OCI/Docker，與 IAM/KMS/PrivateLink 整合，提供掃描、生命周期策略、跨區複寫與細粒度權限。
- 使用場景：ECS/EKS/SageMaker 端到端部署、CI/CD 推送與版本管理、私有映像跨帳號/跨區供應與合規掃描。

➤ Amazon Elastic Container Service (Amazon ECS)

- 定義：是一項全託管的容器管理服務，可讓用戶輕鬆運行、擴展和保護容器化應用。它支持 Docker 容器，並提供彈性且高效的基礎架構，以支持微服務架構。
 - 使用場景：適合需要運行微服務架構的應用、企業級應用和開發測試環境，特別是當需要快速擴展和部署應用時，能夠提高開發效率和資源利用率。此外，ECS 也適合與 AWS 其他服務（如 Fargate 和 Lambda）集成，提升整體解決方案的靈活性。
-

➤ Amazon Elastic Kubernetes Service (Amazon EKS)

- 定義：Amazon EKS 是託管 Kubernetes 服務，免管控制平面，提供自動修補與擴縮，並與 VPC、IAM、ALB、CloudWatch 等深度整合。
- 使用場景：
 - ◆ 微服務與容器編排
 - ◆ CI/CD 滾動更新、藍綠/金絲雀發布
 - ◆ 混合雲與多帳戶多區部署

➤ AWS Fargate

- 定義：AWS 的無伺服器容器執行引擎，搭配 ECS/EKS 執行容器，免管理 EC2/叢集，依資源用量計費與自動擴縮。
 - 使用場景：SageMaker 周邊容器（自訂演算法/前後處理微服務）、事件驅動與批處理任務、彈性 API/工作隊列。
-

➤ Amazon QuickSight ML Insights

- 定義：是一個集成的機器學習功能，提供自動化的數據分析和可視化服務，能夠自動發現

異常、預測趨勢及生成見解，幫助用戶做出數據驅動的決策。

- 使用場景：適合需要快速洞察資料趨勢和異常的商業場景，如銷售分析、客戶行為洞察和市場趨勢預測，讓用戶能夠輕鬆地從巨大數據集中獲得可靠的商業見解，特別對於非技術用戶也能提供可理解的結果。
-

➤ AWS CloudFormation

- 定義：是 AWS 的 IaC 服務，以宣告式模板（YAML/JSON）定義並可重現部署資源；內建資源依賴/回滾/變更集管理，支援跨區域與跨帳號部署（StackSets）。
 - 白話：像雲端基礎設施的「藍圖+施工單」，照圖自動蓋好、壞了可回滾，版本可追蹤。
 - 使用場景：
 - ◆ 建立 SageMaker 端點、Notebook、Feature Store
 - ◆ 佈建 ML 管線資源（Pipelines、Step Functions、EventBridge）
 - ◆ 多帳號一致化環境與權限配置（StackSets）
-

➤ AWS Lake Formation

- 定義：是 AWS 服務，用於快速建立安全的資料湖，整合多源資料（S3、RDS 等），提供資料清理/轉換、集中式權限管控（含欄位/列級），並透過存取控制支援 Athena、Redshift 等分析。
 - 使用場景：
 - ◆ 統一儲存與治理（S3 資料湖+集中授權）
 - ◆ 精細存取控制（欄位/列級、跨帳號分享）
 - ◆ 簡化 ETL 與目錄管理（Glue 整合）
-

➤ Amazon CloudWatch

- 定義：AWS 監控與可觀測性服務，集中蒐集指標、日誌、事件，提供告警、視覺化與自動化動作（規則/事件總線整合）。
- 使用場景：
 - ◆ 模型端點延遲/錯誤率告警
 - ◆ 訓練作業失敗觸發補救（Lambda/Step Functions）
 - ◆ 指標驅動的自動擴縮與再訓練觸發

➤ AWS CloudTrail

- 定義：CloudTrail 是 AWS 稽核與安全性服務，集中記錄與查詢 API/管理事件（誰在何時對哪個資源做了什麼），支援事件歷史、日誌送往 S3/CloudWatch。
- 使用場景：
 - ◆ 調查異常操作與合規稽核
 - ◆ 觸發告警/自動化回應
 - ◆ 追蹤模型與資料資產變更

➤ Amazon CloudFront

- 定義：AWS全球CDN，邊緣快取與路由；整合S3/ALB；支援TLS、WAF/Shield、簽章URL/Cookie、CloudFront Functions/Lambda@Edge。
- 白話：把內容先放到各地節點，就近讀取，速度更快也更安全。
- 使用場景：前端/模型資產發佈、S3私有桶以OAC+簽章授權、動態推論API加速。

➤ 使用指引：

- 追蹤誰做了什麼(API)：CloudTrail。
 - 監控效能/指標、設告警、看日誌：CloudWatch。
 - 全球內容加速與邊緣防護：CloudFront。
-

➤ Amazon Resource Name (ARN)

- 定義：ARN 是 AWS 資源的唯一識別符，格式：arn:partition:service:region:account-id:resource-type/resource-id，用於跨服務精準指定資源（如 IAM 政策、API 呼叫）。
 - 使用場景：
 - ◆ 在 IAM 政策中授權特定資源存取
 - ◆ EventBridge 規則指定觸發目標
 - ◆ 跨服務引用資源（例：Lambda 觸發 SQS）
-

➤ AWS Cost Explorer V.S AWS Budgets

- 定義：
 - ◆ Cost Explorer：視覺化成本分析，提供近12個月成本/用量圖表、篩選與預測。
 - ◆ Budgets：成本控制工具，設預算閾值，超支前發警報或自動行動。
 - 使用場景（ML）：
 - ◆ Cost Explorer：分析 SageMaker 訓練/推論成本（spot vs on-demand）。
 - ◆ Budgets：為端點/實驗設月度上限，防範資源濫用。
-

➤ AWS Compute Optimizer

- 定義：以ML分析CloudWatch用量，對EC2/ASG/EBS/Lambda給出right-sizing與機型/容量建議。
 - 使用場景：訓練/推論伺服器選型、降成本、調整EBS效能、發現低利用率資源。
-

➤ Application Load Balancer (ALB)

- 定義：ALB 是 AWS 的第七層（L7）負載均衡，支援基於 URL/Host/Header/Method 的路由、基於內容的轉發、WebSocket/HTTP2、SSL/TLS 終止、狀態檢查與跨多 AZ 高可用，常用目標類型含 EC2、IP、Lambda。
- 使用場景：
 - ◆ 單網域多服務的路徑/主機名路由
 - ◆ 無伺服器後端（Lambda）HTTP 入口
 - ◆ 藍綠/金絲雀發布與健康檢查切流

➤ (Network) Access Control List ((N)ACL)

- 定義：Network ACL（網絡訪問控制列表）是 AWS 中一種額外的安全層，用來控制進出 VPC 子網的流量。它允許用戶設置規則，以放行或拒絕特定 IP 地址範圍和端口的流量。
 - 使用場景：適合在需要細粒度控制進出流量的應用中，特別是當需要根據來源IP或端口進行流量管理時，比如防止未授權訪問、控制用戶訪問權限或避免DDoS攻擊等，提升整體網絡安全性。Network ACL 也可以與安全組一起使用，以加強 AWS 環境的防禦能力。
-